

Relatório de experimentos - Machine Learning

1. DESCRIÇÃO DO CONJUNTO DE DADOS

O dataset se trata de um problema binário de classificação. Cabendo ao modelo aprender a diagnosticar corretamente tumores mamários como malignos ou benignos.

As features de entrada usadas para previsão são as seguintes:

- a) radius (mean of distances from center to points on the perimeter)
- b) texture (standard deviation of gray-scale values)
- c) perimeter
- d) area
- e) smoothness (local variation in radius lengths)
- f) compactness ($\text{perimeter}^2 / \text{area} - 1.0$)
- g) concavity (severity of concave portions of the contour)
- h) concave points (number of concave portions of the contour)
- i) symmetry
- j) fractal dimension ("coastline approximation" - 1)

Sendo que para cada uma delas há a média, o erro e o pior valor. Com esses dados o modelo deve ser capaz de prever a variável-alvo:

- Diagnosis (M = malignant, B = benign)

O bloco de código inicial é responsável pelo carregamento e estruturação dos dados brutos dentro do ambiente de desenvolvimento.

2. METODOLOGIA EXPERIMENTAL

O protocolo experimental consiste na separação dos dados em três conjuntos disjuntos de desenvolvimento (treinamento e validação) e teste. Sendo que o conjunto de desenvolvimento corresponde a 80% dos dados e o de teste 20%.

O conjunto de desenvolvimento é novamente dividido em treinamento (75%) e validação (25%). O que resulta em uma proporção final de 60% treino, 20% validação e 20% teste sobre os dados originais.

Os algoritmos foram avaliados no conjunto de validação, para ter a seleção do melhor modelo, além do ajuste de hiperparâmetros. O conjunto de teste foi utilizado exclusivamente no final para ratificar a capacidade de generalização do modelo escolhido.

Como estratégia de pré-processamento, as variáveis que apresentam distribuições com assimetria à direita (cauda longa) foram transformadas utilizando a função logarítmica para aproximar seus comportamentos de uma distribuição normal. No caso foram as variáveis com erro no nome e as colunas mean concavity, mean concave points e worst concave points. As demais features foram normalizadas através do método z-score (StandardScaler), por serem consideradas aproximadamente normais. Assim os dados em escalas diferentes não atrapalhariam o modelo linear.

3. TABELAS COM OS RESULTADOS

A tabela 1 contém as métricas dos modelos linear regression, Decision tree e Random Forest no conjunto de validação.

Table 1. Resultados Comparativos - Conjunto de Validação

Modelo	Classe	Precision	Recall	F1-Score
Regressão Logística	Malignant	0.95	1.00	0.98
	Benign	1.00	0.97	0.99
Árvore de Decisão	Malignant	0.90	0.90	0.90
	Benign	0.95	0.95	0.95
Floresta Aleatória	Malignant	0.97	0.95	0.96
	Benign	0.97	0.99	0.98

Relatório acadêmico gerado a partir do arquivo jupyter notebook estruturado com o pipeline experimental de machine learning clássico.

A tabela 2 demonstra o resultado que cada árvore de decisão teve no conjunto de validação no ajuste de hiperparâmetros.

Table 2. Resultados Comparativos - hiperparâmetros

Max Depth	Classe	Precision	Recall	F1-Score
Depth: 3	Malignant	0.95	0.93	0.94
	Benign	0.96	0.97	0.97
Depth: 5	Malignant	0.95	0.90	0.92
	Benign	0.95	0.97	0.96
Depth: 7	Malignant	0.90	0.90	0.90
	Benign	0.95	0.95	0.95
Depth: 9	Malignant	0.90	0.90	0.90
	Benign	0.95	0.95	0.95

Por fim, a tabela 3 contém as métricas dos modelos no conjunto de teste. Vale a pena frisar que o conjunto de teste foi usado apenas para verificar o desempenho final dos modelos e nenhuma decisão foi tomada a partir deles.

Table 3. Resultados Finais de Generalização no Conjunto de Teste

Modelo	Classe	Precision	Recall	F1-Score
Regressão Logística	Malignant	1.00	0.96	0.98
	Benign	0.97	1.00	0.98
Floresta Aleatória	Malignant	0.98	0.98	0.98
	Benign	0.98	0.98	0.98
Árvore de Decisão	Malignant	0.96	0.96	0.96
	Benign	0.97	0.97	0.97
Árvore de Decisão (Depth: 3)	Malignant	0.96	0.94	0.95
	Benign	0.95	0.97	0.96

4. GRÁFICOS PRODUZIDOS

4.1. Análise Exploratória: Histogramas

O primeiro gráfico 1 foi executado para realizar uma análise da frequência visual das features.

4.2. Aprendizado Não Supervisionado: PCA

O segundo gráfico 2 projeta e visualiza o espaço geométrico de dados através de análise estatística linear não-supervisionada usando os dois componentes que capturam o maior coeficiente de variância:




Figure 2. Projeção 2D do Dataset Breast Cancer via PCA.




Figure 1. Matriz de histogramas com a distribuição das features

5. SÍNTESE FINAL

O modelo que obteve melhor desempenho na validação foi o Logistic Regression que teve f1 de 0.98 para as duas classes e recall de 100% para tumores malignos. Vale a pena ressaltar que, dado o contexto dos dados, é muito melhor ter mais falsos tumores malignos do que tumores malignos classificados como benignos. Um paciente com tumor maligno que é liberado corre risco de vida, enquanto um com tumor benigno pode refazer mais exames.

Mesmo assim, todos os modelos atingiram resultados ótimos, a regressão logística foi ligeiramente melhor, além de ter um custo computacional menor se compara a decision tree ou random forest.

O modelo mais simples de interpretar novamente é o logistic regression, justamente por ser o modelo mais simples, ele é linear e os pesos definem um hiperplano na fronteira de decisão para classificar os exemplos na classe positiva ou negativa.

De início, poderia-se pensar que todos os modelos apresentaram sinais de overfitting pelas métricas altíssimas, mas como os dados foram divididos para validar o desempenho, em conjunto de validação e teste não vistos durante o treinamento, essa hipótese é descartada. O que aconteceu realmente foi um ajuste excelente sobre os dados possibilitando ótima generalização, que foi reforçado por métricas similares nos conjuntos de validação e teste, que foi usado somente no final.

Com mais esforço os experimentos poderiam ser mais robustos usando-se abordagem da validação cruzada que daria uma estimativa muito mais acurata do real desempenho de cada abordagem e da variação dos hiperparâmetros que poderiam ser testados em outros

modelos. Além de incluir outros modelos em si como boosting e stacking. Também poderia ser aplicado o PCA para diminuir o número de features no treinamento.